

Traveler Insights UPTC 2026: clasificación de sentimiento en reseñas turísticas con BETO

Documento técnico bajo la metodología CRISP-ML(Q)

Equipo: Team BETO

Integrantes: Juan Tejedor Medina y Miguel Moreno Avendaño

Roles: datos, modelado, evaluación y documentación, con rotación (ver Cierre y Anexo A)

Repositorio: <https://github.com/miguelgerardomoreno-commits/traveler-insights-uptc-2026-beto>

Perfil del equipo en Kaggle:

<https://www.kaggle.com/code/miguelmoreno17/team-beto/notebook>

Octubre de 2026

Resumen

Se ajustó un modelo Transformer para clasificar el sentimiento (negativo, neutral o positivo) de reseñas turísticas en español de Tripadvisor y Foursquare sobre Sucre y Córdoba, en la competencia Traveler Insights UPTC 2026. Se usó BETO con ajuste fino completo y solo el texto del comentario, y se comparó con un baseline de TF-IDF y regresión logística y con XLM-R, con validación cruzada de 5 folds y siete corridas registradas. La métrica oficial es la accuracy. En validación cruzada BETO alcanzó 0,928 frente a 0,897 del baseline (diferencia de 0,031; IC 95 %: 0,011 a 0,052) y en la reserva local 0,917 frente a 0,911. En el leaderboard público obtuvo [completar]. La principal limitación es que la etiqueta se deriva de la valoración promedio del lugar y no de cada reseña, y el modelo parece apoyarse en el estilo del texto y en el nombre del lugar más que en el sentimiento. Además hay solo 22 reseñas negativas, por lo que el recall de esa clase es poco confiable.

Fase 1. Comprensión del negocio y de los datos

1.1 Objetivos

Negocio. El modelo lo usaría una entidad de turismo regional o un operador turístico de Sucre y Córdoba para leer en poco tiempo muchas reseñas de Tripadvisor y Foursquare y decidir a qué sitios dar seguimiento o mejorar primero, a partir de las reseñas críticas. No se propone como medición definitiva de satisfacción sino como apoyo para priorizar la lectura.

ML. Clasificación de texto en tres clases. La entrada es el campo *Comentario* y la salida es *Sentimiento*, codificado como negativo = 0, neutral = 1 y positivo = 2, que es el formato del envío. Las demás columnas no se usan como entrada (sección 1.4).

Tabla 1. Criterios de éxito en tres niveles.

Nivel	Criterio	Cómo se mide
Negocio	Detectar reseñas negativas con un recall igual o mayor al del baseline clásico	Recall de la clase negativa en validación cruzada (809 reseñas)
ML	Superar la accuracy del mejor baseline en al menos 0,02, con un intervalo de confianza de la diferencia que no incluya el cero	Accuracy (métrica oficial) con bootstrap; también F1 macro y recall por clase
Económico	Menos de 100 ms por reseña en GPU y caber en una GPU T4	Latencia mediana por reseña y memoria pico

El margen de 0,02 se fijó antes de entrenar los Transformers. El criterio de negocio se redefinió después de conocer el baseline: se había propuesto un recall de 0,50 y se cambió a "igual o mayor al del baseline", porque con 22 negativos un valor absoluto no se podía defender de antemano.

1.2 Restricciones

GPU Tesla T4 de Kaggle (14,6 GB), tiempo de sesión limitado, máximo de 5 envíos diarios y 2 envíos finales, y equipo de máximo 2 personas en la competencia. Los datos son de uso académico y no comercial. Las licencias de los modelos preentrenados (BETO CC BY 4.0, XLM-R MIT) deben confirmarse en la ficha de cada modelo.

1.3 Análisis exploratorio

train.csv tiene 818 reseñas con etiqueta, **test.csv** tiene 351 con etiqueta y **submission.csv** tiene 129 sin etiqueta, que son las que se deben predecir. Las clases en train son 639 neutrales (78,1 %), 157 positivas (19,2 %) y 22 negativas (2,7 %), así que predecir siempre la clase mayoritaria da una accuracy de 0,781 (Figura 1). Con el tokenizer de BETO, la longitud tiene mediana de 39 tokens, percentil 90 de 112, percentil 95 de 165, percentil 99 de 304 y máximo de 697 (Figura 2). Por clase, la mediana es de 36 tokens en negativas, 46 en neutrales y 16 en positivas.




Figura 1. Distribución de clases en train.




Figura 2. Longitud en tokens por clase (BETO).

El texto es español de la costa Caribe colombiana, con regionalismos y abreviaturas ("chévere", "flia"), algunos textos en inglés y palabras pegadas por la extracción, sobre todo en Foursquare (por ejemplo "Lahamburguesa de pollo elpatacón"). Hay 33 textos de 8 tokens o menos y 9 comentarios duplicados, todos con la misma etiqueta. También hay 22 reseñas con lenguaje de queja cuya etiqueta no es negativa, que son ejemplos ambiguos y evidencia de ruido de etiqueta.

1.4 Calidad de los datos y hallazgos

No hay textos vacíos ni datos personales: la búsqueda por patrones encontró 0 correos, 0 teléfonos y 1 enlace. Dos comentarios del conjunto a predecir y tres de test.csv ya están en train. Tres hallazgos condicionan el resto del trabajo:

1) La etiqueta se deriva de la valoración del lugar y no del texto. Cada combinación de sitio y *Valoración_num* tiene una sola etiqueta: en Foursquare, de 6,4 a 6,9 es neutral y de 7,0 en adelante es positivo, y en Tripadvisor 3,5 es negativo y de 4,0 a 5,0 es neutral. Usar esas columnas convertiría el trabajo en una regla de dos líneas, así que **el modelo usa solo Comentario**.

2) El sitio explica casi toda la etiqueta. Una regla que solo mira el sitio (Foursquare, positivo; Tripadvisor, neutral) alcanza una accuracy de 0,922. Como el estilo del texto delata el sitio (las reseñas positivas son muy cortas y las neutrales largas, y la mediana del año es 2014 en Foursquare y 2019 en Tripadvisor), un modelo puede acertar leyendo el estilo y no el sentimiento.

3) Los negativos salen de solo dos lugares: 19 de la Plaza de Majagual (Tripadvisor) y 3 de un ecoparque de Coveñas. En ese sentido, "negativo" se parece más a "reseña de esos lugares" que a una opinión negativa, y varias de esas reseñas elogian el sitio.

1.5 Factibilidad e hipótesis de trabajo

Con solo el texto el problema se puede resolver de forma parcial: el techo lo limita el ruido de etiqueta y el atajo por sitio. **Hipótesis:** BETO supera al mejor baseline clásico en al menos 0,02 de accuracy y recupera una parte útil de las reseñas negativas.

Tabla 2. Riesgos de calidad y método de QA de la Fase 1.

Riesgo	Cómo se detectó	Evidencia
Desbalance de clases	Conteo por clase	2,7 % negativos; accuracy mayoritaria 0,781
Etiqueta derivada de la valoración del lugar (fuga si se usa <i>Valoración_num</i>)	Agrupación por sitio y valoración	Una sola etiqueta por combinación; se usa solo el texto
Atajo por plataforma	Regla que usa solo el sitio y longitud por clase	Accuracy de la regla 0,922; medianas de 16, 36 y 46 tokens
Clase negativa concentrada en dos lugares	Conteo de negativos por lugar	19 de la Plaza de Majagual y 3 de un ecoparque
Ruido de etiqueta	Búsqueda de quejas en reseñas no negativas	22 reseñas con lenguaje de queja y etiqueta distinta de negativa
Duplicados y solape entre archivos	Comparación de textos exactos	9 duplicados sin conflicto; 2 y 3 textos repetidos de train
Datos personales	Búsqueda por patrones	0 correos, 0 teléfonos, 1 enlace

Fase 2. Ingeniería de datos

2.1 Limpieza y normalización

Se eliminan los enlaces y los espacios repetidos. **No** se pasa a minúsculas, porque BETO distingue mayúsculas; **no** se quitan tildes ni palabras vacías, porque las negaciones cambian el sentido de la reseña; y **no** se corrigen las palabras pegadas, porque una corrección automática puede inventar palabras. Esto contrasta con el baseline, cuyo vectorizador sí pasa a minúsculas.

2.2 Partición

Se eliminan los 9 duplicados (818 a 809) y se crean 5 folds estratificados por etiqueta con semilla 42. Con 22 negativos, una partición 80/20 dejaría cerca de 4 en validación, y con 5 folds cada validación tiene entre 4 y 5 negativos (4, 4, 5, 5 y 4). El fold 0 (647 reseñas para entrenar y 162 para validar) se usa para comparar experimentos y los 5 folds para el resultado final. El archivo *test.csv* queda como reserva sin tocarlo, quitándole los 3 textos repetidos de train (351 a 348 reseñas).

Una partición aleatoria deja los mismos lugares en entrenamiento y validación (el 97,7 % de los lugares del conjunto a predecir ya está en train). Se midió el efecto con el baseline: 0,897 con folds aleatorios y 0,841 con folds agrupados por lugar, y el recall de negativos cae a 0. Se mantiene la partición aleatoria porque imita el conjunto a predecir, y el resultado agrupado se reporta como medida de generalización a lugares nuevos.

2.3 Tokenización, desbalance y aumento de datos

Tabla 3. Porcentaje de textos truncados según *max_length* (tokenizer de BETO, train completo).

<i>max_length</i>	64	128	192	256
Textos truncados	24,6 %	8,4 %	3,3 %	1,2 %

Se tomó *max_length* = 192 como valor base (3,3 % truncado) y se probó 128 en el experimento E4 (Tabla 8). Con 128 el resultado en el fold 0 fue mejor (0,957 frente a 0,944), pero esa diferencia es de 2 reseñas y no es concluyente. Se mantuvo 128 en el modelo final por ser la corrida de mayor accuracy y la más barata. El truncamiento corta el final del texto, y 40 textos de entrenamiento tienen tokens desconocidos (emojis).

Para el desbalance se calcularon pesos de clase completos (11,98 para negativo, 0,43 para neutral y 1,73 para positivo) y con raíz cuadrada (3,46, 0,65 y 1,31). Se compararon como experimentos (E2 y E3) frente a la base sin pesos. No se aplicó aumento de datos.

Tabla 4. Riesgos de calidad y método de QA de la Fase 2.

Riesgo	Método de QA	Evidencia
Fuga entre particiones	Aserciones de IDs y textos disjuntos en los 5 folds y en la reserva	Aserciones superadas en los 5 folds
Duplicados que inflan la validación	Se eliminan antes de partir	9 textos quitados
Pocos negativos por fold	Estratificación y aserción de al menos 3 por fold	4, 4, 5, 5 y 4 negativos
Texto dañado por la limpieza	Limpieza mínima, sin minúsculas ni quitar tildes	Decisión documentada
Pesos de clase demasiado altos	Comparación de pesos completos y con raíz	Experimentos E2 y E3

Fase 3. Ingeniería del modelo

3.1 Baseline clásico

El baseline es TF-IDF de palabras (1 a 2 gramas) y de caracteres (2 a 5) unidos, con regresión logística ($C = 1$). B1a no usa pesos de clase y B1b usa pesos balanceados. B0 predice la clase mayoritaria y B2 usa solo cinco rasgos de forma (longitud, signos de exclamación y de interrogación, proporción de mayúsculas) para medir cuánto se obtiene del estilo sin leer el contenido. Todos se evaluaron en los mismos 5 folds que el Transformer (Tabla 5).

Tabla 5. Baselines en validación cruzada de 5 folds (809 reseñas).

ID	Modelo	Accuracy CV	Desv. entre folds	F1 macro	Recall negativos	Accuracy fold 0
B0	Clase mayoritaria	0,779	0,002	0,292	0,000	0,778
B1a	TF-IDF y regresión logística sin pesos	0,863	0,020	0,516	0,000	0,895
B1b	TF-IDF y regresión logística con pesos	0,897	0,031	0,729	0,318	0,951
B2	Solo forma del texto	0,612	0,029	0,527	0,818	0,654

B1b es el baseline de referencia. Con folds agrupados por lugar, su accuracy baja a 0,841 y su recall de negativos a 0,000. El recall alto de B2 viene acompañado de muchos falsos positivos.

3.2 Selección del checkpoint

Tabla 6. Checkpoints candidatos.

Modelo	Parámetros	Preentrenamiento	Licencia	Resultado
BETO (dccuchile/bert-base-spanish-wwm-cased)	109,9 M	Solo español, con enmascaramiento de palabras completas	CC BY 4.0	Corridas E1 a E6
XLNet base (FacebookAI/xlnet-base)	unos 278 M	100 idiomas (CC100)	MIT	Corrida E7
RoBERTa BNE (PlanTL-GOB-ES/roberta-base-bne)	unos 125 M	Solo español, rastreos web de la Biblioteca Nacional de España	Apache 2.0	E8 no se pudo ejecutar: falló la construcción del tokenizer

Las licencias deben confirmarse en la ficha de cada modelo.

Se eligió BETO como modelo principal por ser monolingüe en español, de tamaño moderado (cabe con holgura en una T4) y de licencia permisiva (Cañete et al., 2020). XLNet (Conneau et al., 2020) sirve para comprobar si cubrir muchos idiomas ayuda, aunque casi todos los textos están en español. RoBERTa BNE (Gutiérrez-Fandiño et al., 2022) quedó sin evaluar por la falla del tokenizer, así que la comparación de checkpoints se limita a BETO y XLNet.

3.3 Arquitectura y configuración de entrenamiento

La arquitectura es un encoder BERT de 12 capas con una cabeza de clasificación (capa pooler y capa lineal de 3 salidas) sobre el token inicial (Devlin et al., 2019; Vaswani et al., 2017). En el ajuste fino se entrenan todos los pesos. En el experimento E6 se congela el encoder y solo aprende la cabeza, lo que sirve para ver cuánto aporta ajustar el encoder.

Tabla 7. Configuración de entrenamiento de la corrida base (E1).

Elemento	Valor
Optimizador	AdamW (Loshchilov y Hutter, 2019), decaimiento de pesos 0,01 salvo en sesgos y normalizaciones
Learning rate y scheduler	2e-5, lineal con warmup del 10 % de los pasos
Batch size y épocas	16 y 6 épocas fijas
Función de pérdida	Entropía cruzada, con pesos de clase según el experimento
Early stopping	No se usa: con una validación de 162 reseñas y 4 negativos, escoger la mejor época sobre ella la sobreajusta. Se fija el número de épocas y se revisan las curvas.
Otros	Recorte de gradiente 1,0, precisión mixta fp16 (Micikevicius et al., 2018), relleno dinámico, semilla 42

3.4 Diseño experimental

Cada experimento cambia un solo factor respecto a E1, con una excepción: en E6 el learning rate sube a 1e-3 porque con el encoder congelado la cabeza no aprende con 2e-5, y ese ajuste va ligado al cambio. Todos se evalúan en el fold 0 y se registran en `registro_experimentos.csv` (Tabla 8).

Tabla 8. Experimentos en el fold 0 (162 reseñas de validación, 4 negativos), métricas de la última época.

ID	Cambio respecto a E1	Accuracy	F1 macro	Recall neg.	Mejor época	Tiempo (s)	Mem. GPU (MB)
E1	Configuración base con BETO	0,944	0,883	1,00	2	41,5	2696
E2	Pesos de clase con raíz cuadrada	0,951	0,914	1,00	3	35,7	2696
E3	Pesos de clase completos	0,938	0,858	1,00	3	36,1	2698
E4	max_length de 128	0,957	0,953	1,00	5	31,6	2298
E5	Learning rate de 5e-5	0,951	0,914	1,00	3	37,2	2692
E6	Encoder congelado (con lr de 1e-3)	0,895	0,569	0,00	5	11,0	593
E7	Checkpoint XLM-R base	0,914	0,593	0,00	2	67,2	5355
E8	Checkpoint RoBERTa BNE	no ejecutó					

E1 a E5 quedan entre 0,938 y 0,957. Una reseña vale 0,006 de accuracy, así que esas diferencias están dentro del ruido.

E6 (0,895) y E7 (0,914) quedan claramente por debajo, y ninguno de los dos detecta negativos. Congelar el encoder cuesta unos 5 puntos de accuracy y mucho F1, de modo que ajustar el encoder sí aporta. Se eligió E4 (mayor accuracy, con desempate por F1 macro) y esa elección se confirmó con validación cruzada. Como E1 a E5 no se distinguen entre sí, la elección de `max_length` 128 no es concluyente y se declara así en las limitaciones.




Figura 3. Accuracy y F1 macro de validación por época para E1 a E7, y pérdidas de entrenamiento y validación de E4.

Diagnóstico de sobreajuste. En E4 la pérdida de validación es mínima en la época 2 (0,170) y sube hasta 0,269 en la época 6, mientras la de entrenamiento baja a 0,012 (Figura 3). Hay sobreajuste. La accuracy y el F1 de validación no empeoran, porque el modelo se hace más seguro sin cambiar la clase predicha en la mayoría de los casos, y el F1 macro de E4 mejora hasta la época 5. Se mantuvieron 6 épocas para no escoger la época sobre una validación tan pequeña. Con más tiempo se reduciría el número de épocas o se usaría una validación más grande.

3.5 Trazabilidad y QA

Todas las corridas se hicieron en Kaggle con Python 3.13.15, PyTorch 2.11.0 (CUDA 12.8), transformers 5.16.1, scikit-learn 1.6.1, numpy 2.1.3, pandas 2.3.3 y una GPU Tesla T4, con semilla 42 y modo determinista de cuDNN. Los registros están en *experiments/* (*env_info.json*, *requirements_exactos.txt*, *registro_experimentos.csv*, *configs.json* y las curvas por corrida). Como comprobación de reproducibilidad, el fold 0 de la validación cruzada repite exactamente las curvas y las métricas de E4.

Tabla 9. Riesgos de calidad y método de QA de la Fase 3.

Riesgo	Método de QA	Evidencia
Sobreajuste a la validación del fold 0	Confirmar con validación cruzada de 5 folds y fijar las épocas sin elegir la mejor	Sección 4.1
Sobreajuste al leaderboard público	Decidir con validación local y registrar cada envío. Envíos usados: 2 de 5 diarios	Archivo <i>envios_kaggle.csv</i>
Comparación injusta con el baseline	Mismos folds, misma semilla y mismo texto limpio	Tabla 5 y Tabla 10
Experimentos no trazables	Cada corrida se guarda en CSV con configuración, métrica y tiempo	<i>registro_experimentos.csv</i>
Falla de un checkpoint (E8)	Se registra el error y se continúa con las demás corridas	Tabla de experimentos

Fase 4. Evaluación del modelo

La evaluación tiene dos partes. Primero, validación cruzada de 5 folds con la configuración elegida (E4), que da una estimación sin sesgo de selección y las predicciones fuera de fold de las 809 reseñas, incluidos los 22 negativos. Segundo, un modelo final entrenado con todo train y evaluado una sola vez sobre la reserva *test.csv*. La métrica oficial es la **accuracy**, pero como el 78 % de las reseñas es neutral y un modelo que siempre responde neutral ya obtiene 0,78, se reportan también precisión, recall y F1 por clase, F1 macro y la matriz de confusión.

4.1 Validación cruzada

Tabla 10. Accuracy por fold del modelo y del baseline.

Fold	n	Accuracy modelo	Accuracy baseline	Recall negativos (modelo)
0	162	0,957	0,951	1,00
1	162	0,901	0,852	0,50
2	162	0,932	0,895	0,40
3	162	0,920	0,895	0,20
4	161	0,932	0,894	0,50
Media		0,928 (desv. 0,020)	0,897	

El modelo supera al baseline en los 5 folds. El recall de negativos varía mucho de un fold a otro (de 0,20 a 1,00) porque cada fold tiene 4 o 5 negativos, lo que muestra lo inestable que es esa medida.

Tabla 11. Métricas en validación cruzada con intervalos de confianza del 95 % por bootstrap (1000 remuestreos).

Modelo	Métrica	Valor	IC 95 %
BETO (E4)	Accuracy (oficial)	0,928	0,910 a 0,946
BETO (E4)	F1 macro	0,817	0,737 a 0,879
BETO (E4)	Recall de negativos	0,500	0,280 a 0,714
Baseline B1b	Accuracy (oficial)	0,897	0,876 a 0,918
Baseline B1b	F1 macro	0,729	0,639 a 0,799
Baseline B1b	Recall de negativos	0,318	0,133 a 0,524

Diferencia pareada de accuracy (BETO menos baseline): 0,031, con IC 95 % de 0,011 a 0,052. Los intervalos del recall de negativos se solapan.

Tabla 12. Precisión, recall y F1 por clase del modelo en validación cruzada (809 reseñas).

Clase	Precisión	Recall	F1	Soporte
Negativo	0,917	0,500	0,647	22
Neutral	0,946	0,965	0,955	630
Positivo	0,857	0,841	0,849	157
Macro	0,906	0,769	0,817	809

La clase negativa tiene precisión alta y recall de 0,50: de 22 negativos recupera 11 y comete un solo falso positivo.




Figura 4. Matrices de confusión en validación cruzada: modelo en conteos, modelo por fila y baseline por fila.

4.2 Reserva test.csv

El modelo final se entrenó con todo train (809 reseñas) y se evaluó una sola vez en la reserva (348 reseñas, 10 negativas). La reserva **no confirma la ventaja** de la validación cruzada: en accuracy el modelo apenas supera al baseline (diferencia de 2 reseñas), y en F1 macro y recall de negativos el baseline queda por encima, aunque con solo 10 negativos los intervalos se solapan casi por completo (Tabla 13).

Tabla 13. Métricas en la reserva test.csv (348 reseñas).

Modelo	Métrica	Valor	IC 95 %
BETO (E4)	Accuracy (oficial)	0,917	0,885 a 0,943
BETO (E4)	F1 macro	0,696	0,589 a 0,798
BETO (E4)	Recall de negativos	0,200	0,000 a 0,500
Baseline B1b	Accuracy (oficial)	0,911	0,882 a 0,940
Baseline B1b	F1 macro	0,774	0,612 a 0,874
Baseline B1b	Recall de negativos	0,400	0,070 a 0,750

Por clase en la reserva (BETO): negativo con precisión 0,500, recall 0,200 y F1 0,286 (10 reseñas); neutral 0,932, 0,963 y 0,947 (271); positivo 0,875, 0,836 y 0,855 (67).

4.3 Análisis de errores

En validación cruzada hay 58 errores en 809 reseñas (Tabla 14). Se revisaron a mano 37: los 12 que involucran la clase negativa y una muestra aleatoria de 25 del resto, cada uno con una categoría y una hipótesis de causa (Tabla 15). Las hipótesis son explicaciones probables y no se comprobaron una a una, salvo la del nombre del lugar, que sí se verificó con la oclusión (sección 4.5).

Tabla 14. Errores del modelo en validación cruzada: real contra predicho.

Real \ Predicho	Negativo	Neutral	Positivo	Total
Negativo	11 (aciertos)	11	0	22
Neutral	0	608 (aciertos)	22	630
Positivo	1	24	132 (aciertos)	157

Total de errores: 58 (11 + 22 + 24 + 1).

Tabla 15. Categorías de los 37 errores revisados.

Categoría	n	Hipótesis de causa	Ejemplos (ID)
Error de etiqueta por valoración del lugar	15	La etiqueta viene de la valoración del lugar y no del texto. En varios casos el modelo acierta con el texto (por ejemplo "Postres deliciosos en Casa Rosa", etiquetada neutral).	887, 279, 210
Texto informativo sin opinión	5	La reseña no valora nada (anuncia una apertura, describe un servicio de Wi-Fi) y la etiqueta sale del lugar.	138, 94
Queja explícita no detectada	4	Solo hay 22 negativos y el modelo se apoya más en el lugar que en palabras de queja. En el ID 851 dice "nos decepcionamos, nada interesante" y el modelo responde neutral con confianza 1,00.	851, 885
Idioma o registro informal	4	Inglés, abreviaturas y mayúsculas sostenidas poco vistos en train ("Peaceful place!", "flia").	54, 60
Atajo por estilo o sitio	4	Reseñas largas y bien escritas de Foursquare se parecen al estilo de Tripadvisor y el modelo responde neutral con confianza casi total.	241, 182
Atajo léxico por el lugar o tema	3	Palabras como "plaza" o "Coveñas" empujan la predicción (ID 224: "Plaza para correr por las mañanas...", etiquetada positiva y predicha negativa).	224, 68
Reseña mixta	2	Elogio y crítica en el mismo texto, con etiqueta ambigua.	865, 269

Más de la mitad de los errores revisados (20 de 37) son ruido de etiqueta o reseñas sin opinión, y no fallas del modelo.

4.4 Robustez

Se evaluó el modelo final en la reserva con textos alterados de forma controlada y con semilla fija (Tabla 16). El modelo resiste bien la pérdida de tildes y mayúsculas y los errores ortográficos moderados, pero **cae 0,474 de accuracy cuando se pegan palabras vecinas**. Ese defecto viene de la extracción de Foursquare, donde las reseñas son neutrales o positivas, y la hipótesis es que el modelo lo usa como marca del sitio. Con textos largos (más de 128 tokens, 29 reseñas) la accuracy es 1,000 y con textos cortos o medios (319) es 0,909; además, en validación cruzada la accuracy es de 0,748 en reseñas de 1 a 16 tokens.

Tabla 16. Robustez del modelo final en la reserva (348 reseñas).

Variante	Accuracy	F1 macro	Caída de accuracy
Original	0,917	0,696	0,000
Errores ortográficos (15 % de las palabras)	0,874	0,703	0,043
Sin tildes ni mayúsculas	0,920	0,796	-0,003
Palabras pegadas	0,443	0,297	0,474

4.5 Explicabilidad

Se usó oclusión por palabra (Zeiler y Fergus, 2014): se quita cada palabra del texto y se mide cuánto baja la probabilidad de la clase predicha. En una reseña de la Plaza de Majagual acertada como negativa ("Una plaza muy típica de ciudades intermedias..."), quitar la palabra "plaza" baja la probabilidad de la clase negativa en 0,95, y ninguna otra palabra pesa más de 0,14. Es decir, el modelo aprendió el nombre del lugar como señal de la clase negativa, no la opinión. En una reseña de la misma plaza clasificada mal, el peso se reparte entre palabras sin carga de opinión ("arquitectura", 0,29). Integrated Gradients no se calculó porque la librería *captum* no estaba instalada. **Advertencia:** estas atribuciones muestran sensibilidad del modelo a ciertas palabras, no una explicación causal, y la atención de un Transformer tampoco equivale a una explicación (Jain y Wallace, 2019).

4.6 Sesgos y privacidad

Tabla 17. Desempeño en validación cruzada por grupo (predicciones fuera de fold).

Grupo	n	Negativos	Accuracy	Recall negativos
Sitio: Foursquare	199	0	0,779	no aplica
Sitio: Tripadvisor	610	22	0,977	0,500
Municipio: Coveñas	292	3	0,969	0,000
Municipio: Sincelejo	189	19	0,772	0,579
Municipio: San Onofre	277	0	0,989	no aplica
Otros municipios (Coloso, Corozal, Tolú, Sincé)	51	0	0,941	no aplica
Longitud: 1 a 16 tokens	111	0	0,748	no aplica
Longitud: 17 a 32 tokens	213	10	0,925	0,600
Longitud: 33 a 64 tokens	286	11	0,958	0,455
Longitud: 65 o más tokens	199	1	0,990	0,000

Dentro de cada sitio, el modelo acierta casi lo mismo que predecir la clase mayoritaria de ese sitio: 0,779 frente a 0,789 en Foursquare y 0,977 frente a 0,964 en Tripadvisor. Su accuracy global viene sobre todo de distinguir el sitio por el estilo: predice positivo para el 75,9 % de las reseñas de Foursquare y para el 0,5 % de las de Tripadvisor. Hay un sesgo por destino: Sincelejo concentra 19 de los 22 negativos y es donde peor le va al modelo (0,772), mientras que en Coveñas no detecta ninguno de los 3. También hay un sesgo por registro: las reseñas muy cortas y las informales son las peor clasificadas.

Mitigaciones propuestas: reetiquetar una muestra con criterio de sentimiento, evaluar siempre con partición agrupada por lugar, aumentar la clase negativa con ejemplos de más lugares, entrenar con ruido de palabras pegadas para que el modelo no use ese defecto como marca del sitio, y reportar los resultados por grupo. **Privacidad:** no se encontraron correos ni teléfonos, las reseñas son texto público de las plataformas, no se identifica a los autores y los datos se usan solo con fines académicos.

4.7 Decisión frente a los criterios de éxito

Tabla 18. Criterios de éxito de la Fase 1 y resultado medido.

Nivel	Criterio	Resultado	¿Cumple?
ML	Accuracy CV mayor al baseline en al menos 0,02	Diferencia de 0,031	Sí
ML	IC de la diferencia sin incluir el cero	Límite inferior de 0,011	Sí
Negocio	Recall de negativos igual o mayor al del baseline	0,500 frente a 0,318	Sí
Económico	Menos de 100 ms por reseña en GPU	11,0 ms (p95: 12,1 ms)	Sí
Económico	Cabe en una T4	704 MB de pico	Sí

Decisión: sí, el modelo cumple los criterios definidos, medidos en validación cruzada. La conclusión debe leerse con cautela por tres razones: la reserva no confirma la ventaja (0,917 frente a 0,911); los intervalos del recall de negativos se solapan con los del baseline; y el modelo se apoya en el estilo del texto y en el nombre del lugar. Por eso se recomienda usarlo como apoyo para priorizar la lectura de reseñas y no como medición confiable de sentimiento mientras no se reetiqueten los datos.

Fase 5. Despliegue

El script `src/inferencia.py` es independiente del notebook: recibe la carpeta del modelo guardado y un CSV con la columna `Comentario`, aplica la misma limpieza y el mismo `max_length` del entrenamiento y escribe el archivo de envío con las columnas `ID` y `Sentimiento` (0, 1 o 2). Se ejecutó como un proceso aparte sobre `submission.csv` y se comprobó que el archivo tiene 129 filas, las columnas correctas, IDs únicos y coincidentes con los de la competencia y solo las clases 0, 1 y 2. Sus predicciones coinciden al 100 % con las del modelo dentro del notebook. La distribución predicha es 75,2 % neutral, 23,3 % positivo y 1,6 % negativo.

Demo. El notebook incluye una función que clasifica una reseña nueva y devuelve la clase con sus probabilidades (Tabla 19). El ejemplo 2 muestra una falla importante: una reseña claramente negativa se clasifica como positiva con

probabilidad de 0,991, coherente con el atajo por estilo y por sitio descrito en la Fase 4.

Tabla 19. Demo con cuatro reseñas escritas para la prueba.

#	Reseña	Predicho	Probabilidad
1	Una playa preciosa, el agua tranquila y la atención de los guías fue excelente. Volveremos pronto.	Neutral	0,999
2	Todo muy sucio y con poca seguridad por la noche, no lo recomiendo.	Positivo	0,991
3	Es un lugar normal, nada del otro mundo, la comida estuvo bien.	Neutral	0,948
4	Pagamos bastante por una comida regular y el servicio fue lento.	Neutral	0,677

Costo de inferencia. Se midió la latencia por reseña de una en una, el rendimiento por lotes, el tamaño y la memoria (Tabla 20). La cuantización dinámica a 8 bits en CPU reduce el tamaño de 420 a 174 MB y la latencia de 88,4 a 53,6 ms, con accuracy de 0,920 en la reserva frente a 0,917 sin cuantizar (una reseña de diferencia).

Tabla 20. Costo de inferencia del modelo final.

Medida	Valor
Parámetros y tamaño en disco	109,9 M de parámetros; 420 MB
GPU T4, una reseña	Latencia mediana 11,0 ms (p95: 12,1 ms)
GPU T4, por lotes	288 reseñas por segundo; memoria pico de 704 MB
CPU, una reseña	Latencia mediana 88,4 ms (p95: 155,0 ms)
CPU con cuantización a 8 bits	53,6 ms; 174 MB; accuracy en la reserva 0,920

Tabla 21. Riesgos de calidad y método de QA de la Fase 5.

Riesgo	Método de QA	Evidencia
Envío con formato inválido	Aserciones sobre columnas, número de filas, IDs y clases	Archivo de 129 filas validado
Diferencias entre el script y el notebook	Comparar las predicciones de ambos	Coincidencia del 100 %
Costo no medido	Latencia, memoria y tamaño en GPU y CPU	Tabla de costo
Pérdida de precisión al comprimir	Evaluar el modelo cuantizado en la reserva	0,920 frente a 0,917

Fase 6. Monitoreo y mantenimiento

6.1 Qué se monitorearía

Una vez en uso el modelo no recibe etiquetas, así que se vigilan señales indirectas y se revisa cada mes una muestra pequeña de 50 reseñas etiquetadas a mano. Las señales son la distribución de clases predichas, la confianza media, la longitud de los textos (con una prueba KS contra la referencia) y el porcentaje de textos con tokens desconocidos, que detecta vocabulario nuevo. Se simularon sobre la reserva, el conjunto a predecir y tres variantes con cambio de distribución (Tabla 22).

Tabla 22. Señales de monitoreo simuladas.

Conjunto	n	% neg.	% neutral	% pos.	Confianza media	Tokens (mediana)	% token desc.	KS longitud
Referencia (reserva)	348	1,1	80,5	18,4	0,984	38	4,3	-
Conjunto a predecir	129	1,6	75,2	23,3	0,986	36	5,4	0,063
Reserva con ruido	348	0,0	17,2	82,8	0,960	44,5	4,3	0,095
Solo Foursquare	90	1,1	28,9	70,0	0,957	16	5,6	0,564
Solo reseñas largas	29	0,0	100,0	0,0	0,999	168	6,9	0,917

La distribución de clases predichas y la longitud reaccionan con claridad (con ruido, los positivos pasan de 18 % a 83 %), mientras que la confianza media casi no cambia (de 0,984 a 0,957), por lo que no sirve como alarma única. El conjunto a predecir se parece a la referencia (KS de 0,063), así que no se espera una degradación fuerte en el envío a la competencia.

6.2 Simulación de drift

Para medir la degradación con un cambio real de distribución se reentrenó el modelo dejando afuera un grupo y se probó justo en ese grupo: un destino nuevo (Coveñas) y una época nueva (reseñas de 2018 en adelante, entrenando con años anteriores). La referencia es la accuracy del mismo modelo en esas reseñas con la validación cruzada normal (Tabla 23). No se dejó afuera Sincelejo porque tiene 19 de los 22 negativos y el modelo quedaría sin ejemplos de esa clase.

Tabla 23. Degradación por cambio de distribución.

Escenario	n prueba (neg.)	Accuracy modelo: referencia a drift	Caída modelo	Accuracy baseline: referencia a drift	Recall neg. modelo: referencia a drift
Destino nuevo: Coveñas	292 (3)	0,969 a 0,959	0,010	0,949 a 0,925	0,00 a 0,00
Época nueva: 2018 en adelante	395 (8)	0,982 a 0,970	0,013	0,977 a 0,901	0,62 a 0,50

La caída del modelo es pequeña en los dos escenarios (0,010 y 0,013) y menor que la del baseline en el cambio de época (0,076). Con tan pocos negativos, el recall no permite sacar conclusiones. La degradación grande aparece con cambios de forma del texto (palabras pegadas, cae 0,474), no con cambios de destino o de época.

6.3 Criterios de reentrenamiento y responsable

Tabla 24. Umbrales de alerta, acción y responsable.

Señal	Umbral de alerta	Acción	Responsable
Accuracy en la muestra mensual etiquetada	Cae más de 0,05 frente a la referencia	Reentrenar con las reseñas nuevas etiquetadas	Modelado
Porcentaje de negativos predichos	Se duplica o baja a la mitad durante dos semanas	Revisar la fuente y etiquetar una muestra	Datos
Confianza media	Baja más de 0,10	Revisar ejemplos de baja confianza	Evaluación
Textos con token desconocido	Sube más de 5 puntos porcentuales	Revisar limpieza y vocabulario	Datos
Prueba KS de longitud	Mayor a 0,20 frente a la referencia	Investigar si hay una plataforma o formato nuevo	Datos
Destino o plataforma nuevos	Siempre	Etiquetar una muestra y evaluar antes de usar el modelo	Evaluación

Además se programa una revisión trimestral. Documentación registra cada cambio de versión del modelo.

Tabla 25. Riesgos de calidad y método de QA de la Fase 6.

Riesgo	Método de QA	Evidencia
Cambio de distribución no detectado	Señales de monitoreo y prueba KS de longitud	Tabla de señales simuladas
Degradación por cambio de destino o época	Reentrenar dejando un grupo afuera	Caídas de 0,010 y 0,013
Fragilidad ante ruido de forma	Perturbaciones del texto en la reserva	Caída de 0,474 con palabras pegadas

Cierre

Conclusiones

El trabajo buscaba saber si un Transformer ajustado solo con el texto de la reseña supera a un baseline clásico y recupera las reseñas negativas. La respuesta es afirmativa en validación cruzada, pero con una ventaja pequeña que la reserva no confirma. BETO con *max_length* de 128 alcanzó 0,928 de accuracy frente a 0,897 del mejor baseline (diferencia de 0,031, IC 95 % de 0,011 a 0,052) y ganó en los 5 folds; el F1 macro subió de 0,729 a 0,817 y el recall de negativos de 0,318 a 0,500. En la reserva, la accuracy fue de 0,917 frente a 0,911, y el F1 macro y el recall de negativos favorecieron al baseline. En el leaderboard público el puntaje fue 0.92.

Frente a los criterios de la Fase 1, el modelo cumple los cinco. Sin embargo, una regla que solo mira el sitio alcanza 0,922, la accuracy cae 0,474 con palabras pegadas, la palabra "plaza" pesa 0,95 para la clase negativa y más de la mitad de los errores revisados son ruido de etiqueta o reseñas sin opinión. La conclusión es que el modelo capta sobre todo el estilo y el lugar, y que sirve como apoyo para priorizar la lectura de reseñas, no como medición confiable de sentimiento. El modelo es liviano de operar: 109,9 M de parámetros, 11 ms por reseña en GPU y 54 ms en CPU con

cuantización.

Limitaciones y trabajo futuro

Limitaciones. (1) La etiqueta se deriva de la valoración del lugar y no de la reseña. (2) Hay solo 22 negativos en train y 10 en la reserva, de apenas dos lugares, así que el recall de esa clase tiene intervalos muy anchos y no se sabe si generaliza a lugares nuevos. (3) Los experimentos se compararon en un solo fold y con una sola semilla, y E1 a E5 no se distinguen entre sí. (4) E8 (RoBERTa BNE) falló por un problema del tokenizer, por lo que se comparan dos checkpoints. (5) Hay sobreajuste después de la época 2. (6) No se corrigieron las palabras pegadas ni los textos en inglés, y Integrated Gradients no se calculó.

Trabajo futuro. Reetiquetar una muestra con criterio de sentimiento, repetir los experimentos con varias semillas, combinar las mejores configuraciones, aumentar la clase negativa (retrotraducción y paráfrasis con control de calidad), entrenar con ruido de palabras pegadas, reducir las épocas y reemplazar E8 por otro modelo en español.

Declaración de uso de IA generativa

El grupo usó Claude (Anthropic), en la aplicación web, como tutor, asistente de programación y asistente de redacción. La herramienta ayudó a interpretar el enunciado y la rúbrica, proponer el plan por fases, escribir el código del notebook y del script de inferencia, detectar los hallazgos de los datos, proponer un borrador de categorías y causas para los errores y redactar el resumen y el cierre. No se usó IA generativa para etiquetar ni predecir datos de la competencia. Ningún LLM se usó como modelo ni como comparador: el modelo principal es un BETO ajustado por el grupo. No se hizo etiquetado manual sobre los conjuntos de validación o de prueba para entrenar o seleccionar el modelo. La revisión manual de errores solo se usó para el análisis. Los archivos de la competencia se compartieron con la herramienta para análisis, con fines académicos y no comerciales.

El grupo ejecutó el notebook completo en Kaggle y validó los resultados con las salidas (aserciones, comparación entre corridas, coincidencia exacta entre el script y el notebook y reproducción de las curvas del fold 0). Los criterios de éxito se fijaron antes de entrenar los Transformers, con una excepción que se declara: el criterio de recall de negativos pasó de 0,50 a "igual o mayor al del baseline" después de conocer los resultados del baseline. El detalle de cada uso está en el Anexo A.

Contribución individual

Tabla 26. Contribución de cada integrante (reparto 50 % y 50 %).

Integrante	Roles	Contribución concreta
Juan Tejedor Medina	Datos y evaluación (rotó con modelado)	Fases 1, 2 y 4: análisis exploratorio, hallazgos sobre la etiqueta y el atajo por sitio, partición en 5 folds y aserciones contra fuga, elección de <i>max_length</i> , métricas por clase, intervalos de confianza, matrices de confusión, pruebas de robustez y análisis de sesgos. Revisión de 18 de los 37 errores.
Miguel Moreno Avendaño	Modelado y despliegue (rotó con datos)	Fases 3, 5 y 6: baselines, selección de checkpoints, bucle de entrenamiento, diseño y registro de los experimentos E1 a E8, curvas y diagnóstico de sobreajuste, script de inferencia y envío, demo, costo, cuantización, monitoreo y simulación de drift. Revisión de 19 de los 37 errores.
Ambos (50 % y 50 %)	Documentación	Cada uno revisó el código y el texto de la parte del otro, llevó la bitácora de IA de sus propias consultas, escribió en conjunto las conclusiones y limitaciones y prepara la defensa sobre todo el proyecto.

El trabajo se repartió en partes iguales. Los roles de datos, modelado, evaluación y documentación rotaron a lo largo del proyecto (registro en el Anexo A).

Referencias

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., y Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. *PML4DC at ICLR 2020*.

Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., y Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. *Proceedings of ACL 2020*, 8440-8451.

Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171-4186.

- Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman and Hall.
- Gutiérrez-Fandiño, A., et al. (2022). MarIA: Spanish language models. *Procesamiento del Lenguaje Natural*, 68, 39-60.
- Jain, S., y Wallace, B. C. (2019). Attention is not explanation. *Proceedings of NAACL-HLT 2019*, 3543-3556.
- Jurafsky, D., y Martin, J. H. (s. f.). *Speech and language processing* (3.ª ed., borrador en línea).
- Loshchilov, I., y Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*.
- Micikevicius, P., et al. (2018). Mixed precision training. *International Conference on Learning Representations (ICLR)*.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., y Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction*, 3(2), 392-413.
- Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of EMNLP 2020: System Demonstrations*, 38-45.
- Zeiler, M. D., y Fergus, R. (2014). Visualizing and understanding convolutional networks. *European Conference on Computer Vision (ECCV)*, 818-833.

Anexo A. Bitácora de uso de IA generativa

Herramienta: Claude (Anthropic), en la aplicación web. Las fechas se completan con las de cada consulta. El mismo contenido está en *docs/bitacora_ia.md*.

#	Propósito	Prompt resumido	Qué se aceptó	Qué se corrigió	Cómo se validó
1	Entender la actividad y la rúbrica	Se pegaron el enunciado y la rúbrica y se pidió un resumen de lo que se exige.	Resumen de entregables, pesos de la rúbrica y requisitos obligatorios.	Nada. La herramienta señaló una posible errata del enunciado (la estructura está en la sección 2 y no en la 3) y avisó que no conocía la tarea concreta de la competencia.	Se contrastó con el enunciado original.
2	Plan de trabajo	Se pidió una lista de pasos para desarrollar la actividad como Team BETO.	Plan por pasos que alimenta cada criterio de la rúbrica.	El grupo pidió que el notebook se organizara por las fases de CRISP-ML(Q) y no por pasos, con una sola celda que cargue todas las librerías.	Se contrastó con la estructura exigida en el enunciado.
3	Configuración inicial en Kaggle	Se pidió la celda de semilla, rutas y registro del entorno, con Markdown natural y comentarios simples.	Celdas de semilla global, rutas y registro del entorno en un JSON.	Se ajustaron las rutas reales de los archivos de la competencia y se pidió quitar guiones de los comentarios.	Ejecución en Kaggle con GPU T4 y revisión de env_info.json.
4	Repositorio con Git y Visual Studio Code	Se pidieron los pasos para crear el repositorio y ubicar la terminal, y el .gitignore.	Estructura de carpetas, .gitignore y data/README.md.	Se adaptaron los comandos al sistema operativo del grupo (PowerShell frente a Bash).	git status y git check-ignore sobre los CSV de la competencia.
5	Revisión de los datos de la competencia	Se subieron train.csv, test.csv y submission.csv y se pidió identificar la tarea y la estructura.	Hallazgos: test.csv trae etiquetas, la etiqueta se deriva de la valoración del lugar y del sitio, y los negativos se concentran en dos lugares.	La herramienta aclaró que no conocía la métrica ni las reglas. El grupo aportó las reglas de la competencia: la métrica oficial es la accuracy, el formato del envío usa 0, 1 y 2, y el equipo es de máximo 2 personas.	Las tablas se reprodujeron en las celdas de la Fase 1 del notebook.
6	Errores de ejecución en el notebook	Se pegaron un NameError por el orden de las celdas y una falla al descargar el tokenizer sin Internet.	Ejecutar la celda de carga antes de las demás y activar Internet o agregar el modelo como input.	Nada.	El notebook corrió después de aplicar los cambios.
7	Fases 1 y 2: exploración, partición y aserciones	Se pidieron el EDA con longitud en tokens, la partición y las pruebas del pipeline.	Celdas de EDA, 5 folds estratificados, aserciones contra fuga y pesos de clase.	El grupo decidió usar solo el texto del comentario y dejar test.csv como reserva hasta el final.	Aserciones superadas en los 5 folds y salidas de las celdas.
8	Notebook completo de las Fases 0 a 6	Se pidió generar todo el notebook hasta la Fase 6 cumpliendo los requisitos de la rúbrica.	Notebook de 66 celdas con baselines, entrenamiento en PyTorch, evaluación, script de inferencia, monitoreo y simulación de drift.	El criterio de negocio pasó de un recall de 0,50 a un recall igual o mayor al del baseline, después de conocer el desempeño del baseline.	La herramienta lo probó antes con un modelo diminuto en CPU. El grupo lo ejecutó en Kaggle con GPU y se verificó que el fold 0 de la validación cruzada reproduce la corrida E4.
9	Interpretación de los resultados del notebook ejecutado	Se subió el notebook con salidas y se pidió indicar los cambios encontrados y si cumple los criterios.	Lectura del atajo por estilo y por sitio, del contraste entre validación cruzada y reserva, y de la falla de E8.	El grupo decidió entregar con siete corridas y declarar la falla de E8 como limitación.	Con la oclusión por palabra, las tablas por sitio y la prueba de robustez del propio notebook.

#	Propósito	Prompt resumido	Qué se aceptó	Qué se corrigió	Cómo se validó
10	Categorización de errores	Se subió errores_para_revisar.csv y se pidió una categoría y una hipótesis de causa por reseña.	Borrador de 37 categorías con hipótesis, guardado como diccionario CATEGORIAS.	Se verifico las categorías, culminando en aceptación de las categorización realizada.	[confirmar; lectura de cada reseña por los integrantes]. Las hipótesis sin prueba se marcaron como hipótesis.
11	Resumen, conclusiones y declaración de IA	Se subió resumen_final.json y se pidió el resumen, las conclusiones, las limitaciones y la declaración de uso de IA.	Textos del resumen, del cierre y de la declaración.	Se verifica y se realiza pequeñas correcciones.	Cifras contrastadas con resumen_final.json y con las salidas del notebook.
12	Documento técnico y bitácora	Se pidieron los dos archivos de la carpeta docs.	PDF del documento técnico y esta bitácora.	Se verifica todo el documento para realizar cambios en detalles no especificados a la IA.	Cifras y tablas contrastadas con las salidas del notebook ejecutado y con resumen_final.json.

Usos que no se hicieron. No se usó IA generativa para etiquetar ni predecir datos de la competencia. Ningún LLM se usó como modelo ni como comparador: el modelo principal es un BETO ajustado por el grupo. No se hizo etiquetado manual sobre los conjuntos de validación o de prueba para entrenar o seleccionar el modelo. La revisión manual de errores solo se usó para el análisis. Los archivos de la competencia se compartieron con la herramienta para análisis, con fines académicos y no comerciales.

Registro de roles rotativos

Etapas	Datos	Modelado	Evaluación	Documentación
Etapas 1: Fases 0 a 2 (datos y partición)	Juan	Juan	Juan	Miguel
Etapas 2: Fase 3 (modelo y experimentos)	Miguel	Miguel	Miguel	Miguel
Etapas 3: Fases 4 a 6 y documento	Juan	Juan	Miguel	Miguel